

Kategorisieren der Marsoberfläche mithilfe von Unsupervised Learning durch Backpropagation

Merlin Scholz
merlin.scholz@tu-dortmund.de

Mustererkennung,
Informatik XII, Technische Universität Dortmund
20. November 2019

Inhalt

- ▶ Motivation
- ▶ Verwandte Arbeiten
- ▶ Vorgehensweise
- ▶ Referenzen

Motivation: Neuronale Netze zur Bildsegmentierung

- ▶ Neuronale Netzwerke werden oft zur Bildsegmentierung genutzt
- ▶ Voraussetzung: Manuell erstellte Ground Truth um das Netzwerk zu trainieren



Figure: Beispiel: CityScapes Dataset[5]

Motivation: (Fehlende) Ground Truths

Ground Truth nicht immer vorhanden: Beispiel Marsoberfläche

- ▶ Zu großer Datensatz
- ▶ Notwendigkeit von Experten
- ⇒ Manuelle Erstellung nicht kostengünstig oder zeiteffizient möglich

Lösungsansatz:

- ▶ Anfangs zufällige Klassifizierung durch Segmentierungsalgorithmus weiter optimieren

Verwandte Arbeiten: Segmentierung nach Kanezaki[7]

- Unüberwachtes Lernen der Segmentierung
- Anfangs zufällige Ergebnisse werden mit Clusteringalgorithmus vereint
- Zielfunktion: Softmax-Loss zwischen Ergebnis des NN und des optimierten Ergebnisses
- NN wird auf diese Zielfunktion hin optimiert (Backpropagation)




Figure: Vorgehensweise nach Kanezaki[7]

Detection of craters [...] using shape and texture features nach Bandeira[2]

1. Vorsortierung basierend auf Urbach & Stepinskis Algorithmus[11] zur Kratererkennung
 - ▶ Effiziente Methode zur Krater-Erkennung
 - ▶ 70% Erkennungsrate
 - ▶ Funktionsweise über Schatten und Highlights
2. Überlagerung von 9 Bitmasken (in versch. Positionen) und Prüfung auf Übereinstimmungen
3. Anwendung eines angepassten AdaBoost Algorithmus
4. Post-Processing: Eliminierung von ungewöhnlich geformten Kratern




Figure: Erkannte Krater nach Bandeira[2]

Hierauf basierend: Der Krater-Datensatz der University of Massachusetts[8]

Verwandte Arbeiten: Crater Detection via CNNs[4]

- ▶ Erforscht Neuronale Netze statt manuell erstellten Gabor-/ Sobel-Filtern

Vorgehensweise: Implementierung

- ▶ Grundlegende Idee ähnlich zu Kanezaki[7], basierend auf PyTorch
- ▶ Benutzung von Python Bibliotheken nicht immer möglich (zu große Eingabedaten, bspw. bei SLIC[1])
- ⇒ Speichereffizienter neu implementieren, ggf. über Sliding-Window-Verfahren
- ▶ Für bessere Performance wird oft auf Cython[3] zurück gegriffen

Vorgehensweise: Erweiterung

Zur Optimierung der Ergebnisse werden einzelne Teile des Algorithmus ersetzt:

- ▶ Ersetzen des relativ einfachen Neuronalen Netzes durch größere, bspw. ImageNet, Faster R-CNNs, YOLOv3, etc.
- ▶ Ersetzen des SLIC Clusteringalgorithmus durch bspw. k-Means Clustering oder Mean-Shift Clustering

Vorgehensweise: Evaluierung (1)

Um die Alternativen evaluieren zu können, wird der Algorithmus auf Datensätze mit vorhandenen Ground Truths angewandt:

- ▶ *Common Objects In Context*[9]
- ▶ *Cityscapes Dataset*[6]
- ⇒ Weit verbreitete Datensätze zur Bildsegmentierung
- ▶ *Crater Dataset* des UMass Boston
- ▶ *The Prague Texture Segmentation Datagenerator and Benchmark*[10]
KDLab[8]
- ⇒ Den zu analysierenden Daten sehr ähnlich, also realitätsnaher

Vorgehensweise: Evaluierung (2)

Die generierten Resultate werden mit den jeweils zugehörigen Ground Truths verglichen.

Vorgehensweise: Evaluierung (2)

Die generierten Resultate werden mit den jeweils zugehörigen Ground Truths verglichen.

Hinweis

Metriken, die auf Clusterlabels basieren sind nur eingeschränkt nutzbar

Vorgehensweise: Evaluierung (2)

Die generierten Resultate werden mit den jeweils zugehörigen Ground Truths verglichen.

Hinweis

Metriken, die auf Clusterlabels basieren sind nur eingeschränkt nutzbar

Hinweis

Zum Vergleich müssen die jeweiligen NNs den selben Seed nutzen

Vorgehensweise: Optimierungen

- ▶ Eingabebilder in Graustufen: Optimierung des Clusterings und des NNs
- ▶ Parallelisierung entweder pro Bild oder mehrere Bilder parallel

Referenzen

-  R. ACHANTA, A. SHAJI, K. SMITH, A. LUCCHI, P. FUA and S. SÜSSTRUNK: *SLIC Superpixels*. p. 15, 2010.
-  L. BANDEIRA, W. DING and T. F. STEPINSKI: *Detection of sub-kilometer craters in high resolution planetary images using shape and texture features*. Advances in Space Research, 49(1):64–74, 2012.
-  S. BEHNEL, R. BRADSHAW, C. CITRO, L. DALCIN, D. SELJEBOTN and K. SMITH: *Cython: The Best of Both Worlds*. Computing in Science Engineering, 13(2):31 –39, 2011.
-  J. P. COHEN, H. Z. LO, T. LU and W. DING: *Crater Detection via Convolutional Neural Networks*. arXiv e-prints, p. arXiv:1601.00978, Jan 2016.
-  M. CORDTS, M. OMRAN, S. RAMOS, T. REHFELD, M. ENZWEILER, R. BENENSON, U. FRANKE, S. ROTH and B. SCHIELE: *The Cityscapes Dataset for Semantic Urban Scene Understanding*. In *The IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2016.
-  M. CORDTS, M. OMRAN, S. RAMOS, T. REHFELD, M. ENZWEILER, R. BENENSON, U. FRANKE, S. ROTH and B. SCHIELE: *The Cityscapes Dataset for Semantic Urban Scene Understanding*. In *Proc. of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016.
-  A. KANEZAKI: *Unsupervised Image Segmentation by Backpropagation*. In *Proceedings of IEEE International Conference on Acoustics, Speech, and Signal Processing (ICASSP)*, 2018.
-  U. B. KD LAB: *Crater Dataset*. 2013.
-  T.-Y. LIN, M. MAIRE, S. BELONGIE, J. HAYS, P. PERONA, D. RAMANAN, P. DOLLÁR and C. L. ZITNICK: *Microsoft COCO: Common Objects in Context*. In *European Conference on Computer Vision (ECCV)*, 2014.
-  S. MIKEŠ, M. HAINDL, G. SCARPA and R. GAETANO: *Benchmarking of Remote Sensing Segmentation Methods*. IEEE JOURNAL OF SELECTED TOPICS IN APPLIED EARTH OBSERVATIONS AND REMOTE SENSING, 8(5), 2015.
-  E. R. URBACH and T. F. STEPINSKI: *Automatic detection of sub-km craters in high resolution planetary images*. Planetary and Space Science, 57(7):880–887, 2009.