

Kategorisieren der Marsoberfläche mithilfe von Unsupervised Learning durch Backpropagation

Merlin Scholz
merlin.scholz@tu-dortmund.de

Mustererkennung,
Informatik XII, Technische Universität Dortmund
20. November 2019

Inhalt

- ▶ Motivation
- ▶ Verwandte Arbeiten
- ▶ Vorgehensweise
- ▶ Referenzen

Motivation: Neuronale Netze zur Bildsegmentierung

- ▶ Neuronale Netzwerke werden oft zur Bildsegmentierung genutzt
- ▶ Voraussetzung: Manuell erstellte Ground Truth um das Netzwerk zu trainieren



Figure: Beispiel: CityScapes Dataset[5]

Motivation: (Fehlende) Ground Truths

Ground Truth nicht immer vorhanden: Beispiel Marsoberfläche

- ▶ Zu großer Datensatz
- ▶ Notwendigkeit von Experten
- ⇒ Manuelle Erstellung nicht kostengünstig oder zeiteffizient möglich

Lösungsansatz:

- ▶ Anfangs zufällige Klassifizierung durch Segmentierungsalgorithmus weiter optimieren

Verwandte Arbeiten: Segmentierung nach Kanezaki[7]

- Unüberwachtes Lernen der Segmentierung
- Anfangs zufällige Ergebnisse werden mit Clusteringalgorithmus vereint
- Zielfunktion: Softmax-Loss zwischen Ergebnis des NN und des optimierten Ergebnisses
- NN wird auf diese Zielfunktion hin optimiert (Backpropagation)




Figure: Vorgehensweise nach Kanezaki[7]

Detection of craters [...] using shape and texture features nach Bandeira[2]

1. Vorsortierung basierend auf Urbach & Stepinski's Algorithmus[11] zur Kratererkennung
 - ▶ Effiziente Methode zur Krater-Erkennung
 - ▶ 70% Erkennungsrate
 - ▶ Funktionsweise über Schatten und Highlights
2. Überlagerung von 9 Bitmasken (in versch. Positionen) und Prüfung auf Übereinstimmungen
3. Anwendung eines angepassten AdaBoost Algorithmus
4. Post-Processing: Eliminierung von ungewöhnlich geformten Kratern




Figure: Erkannte Krater nach Bandeira[2]

Hierauf basierend: Der Krater-Datensatz der University of Massachusetts[8]
(vergleichbar mit unserem Ziel)

Verwandte Arbeiten: Crater Detection via CNNs[4]

- ▶ Erforscht Neuronale Netze statt manuell erstellten Gabor-/ Sobel-Filtern
- ▶ “Klassischer” Ansatz über neuronale Netze
- ▶ Lernt auf Bandeira-Datensatz der UMass[8]
- ▶ Nutzt F1-Score und Cross Validation zur Evaluierung
- ▶ Gute Ergebnisse, F1-Score zwischen 88% und 91% (vgl. Bandeira 79% – 86%)

Vorgehensweise: Datensatz

Vorgehensweise: Implementierung

- ▶ Grundlegende Idee ähnlich zu Kanezaki[7], basierend auf PyTorch
- ▶ Benutzung von Python Bibliotheken nicht immer möglich (zu große Eingabedaten, bspw. bei SLIC[1])
- ⇒ Speichereffizienter neu implementieren, ggf. über Sliding-Window-Verfahren
- ▶ Für bessere Performance wird oft auf Cython[3] zurück gegriffen

Vorgehensweise: Erweiterung

Zur Optimierung der Ergebnisse werden einzelne Teile des Algorithmus ersetzt:

- ▶ Ersetzen des relativ einfachen Neuronalen Netzes durch größere, bspw. ImageNet, Faster R-CNNs, YOLOv3, etc.
- ▶ Ersetzen des SLIC Clusteringalgorithmus durch bspw. k-Means Clustering oder Mean-Shift Clustering

Vorgehensweise: Evaluierung (1)

Um die Alternativen evaluieren zu können, wird der Algorithmus auf Datensätze mit vorhandenen Ground Truths angewandt:

- ▶ *Common Objects In Context*[9] oder das *Cityscapes Dataset*[6]
⇒ Weit verbreitete Datensätze zur Bildsegmentierung
- ▶ *The Prague Texture Segmentation Datagenerator and Benchmark*[10]
⇒ Den zu analysierenden Daten sehr ähnlich, also realitätsnaher

Vorgehensweise: Evaluierung (2)

Die generierten Resultate werden mit den jeweils zugehörigen Ground Truths verglichen, bspw. über F1-Score

Vorgehensweise: Evaluierung (2)

Die generierten Resultate werden mit den jeweils zugehörigen Ground Truths verglichen, bspw. über F1-Score

Hinweis

Metriken, die auf Clusterlabels basieren sind nur eingeschränkt nutzbar

Vorgehensweise: Evaluierung (2)

Die generierten Resultate werden mit den jeweils zugehörigen Ground Truths verglichen, bspw. über F1-Score

Hinweis

Metriken, die auf Clusterlabels basieren sind nur eingeschränkt nutzbar

Hinweis

Zum Vergleich müssen die jeweiligen NNs den selben Seed nutzen

Vorgehensweise: Optimierungen

- ▶ Eingabebilder in Graustufen: Optimierung des Clusterings und des NNs
- ▶ Parallelisierung entweder pro Bild oder mehrere Bilder parallel
- ▶ Wahl des am besten geeigneten Clustering-Algorithmus
- ▶ Wahl des am besten geeigneten Aufbaus des NNs

Referenzen

-  R. ACHANTA, A. SHAJI, K. SMITH, A. LUCCHI, P. FUA and S. SÜSSTRUNK: *SLIC Superpixels*. p. 15, 2010.
-  L. BANDEIRA, W. DING and T. F. STEPINSKI: *Detection of sub-kilometer craters in high resolution planetary images using shape and texture features*. Advances in Space Research, 49(1):64–74, 2012.
-  S. BEHNEL, R. BRADSHAW, C. CITRO, L. DALCIN, D. SELJEBOTN and K. SMITH: *Cython: The Best of Both Worlds*. Computing in Science Engineering, 13(2):31 –39, 2011.
-  J. P. COHEN, H. Z. LO, T. LU and W. DING: *Crater Detection via Convolutional Neural Networks*. arXiv e-prints, p. arXiv:1601.00978, Jan 2016.
-  M. CORDTS, M. OMRAN, S. RAMOS, T. REHFELD, M. ENZWEILER, R. BENENSON, U. FRANKE, S. ROTH and B. SCHIELE: *The Cityscapes Dataset for Semantic Urban Scene Understanding*. In *The IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2016.
-  M. CORDTS, M. OMRAN, S. RAMOS, T. REHFELD, M. ENZWEILER, R. BENENSON, U. FRANKE, S. ROTH and B. SCHIELE: *The Cityscapes Dataset for Semantic Urban Scene Understanding*. In *Proc. of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016.
-  A. KANEZAKI: *Unsupervised Image Segmentation by Backpropagation*. In *Proceedings of IEEE International Conference on Acoustics, Speech, and Signal Processing (ICASSP)*, 2018.
-  U. B. KDLAB: *Crater Dataset*. 2013.
-  T.-Y. LIN, M. MAIRE, S. BELONGIE, J. HAYS, P. PERONA, D. RAMANAN, P. DOLLÁR and C. L. ZITNICK: *Microsoft COCO: Common Objects in Context*. In *European Conference on Computer Vision (ECCV)*, 2014.
-  S. MIKEŠ, M. HAINDL, G. SCARPA and R. GAETANO: *Benchmarking of Remote Sensing Segmentation Methods*. IEEE JOURNAL OF SELECTED TOPICS IN APPLIED EARTH OBSERVATIONS AND REMOTE SENSING, 8(5), 2015.
-  E. R. URBACH and T. F. STEPINSKI: *Automatic detection of sub-km craters in high resolution planetary images*. Planetary and Space Science, 57(7):880–887, 2009.